Teste prático - Engenharia de Dados Jr.

Contexto

A pessoa candidata atuará no desenvolvimento e manutenção de soluções de integração de dados aplicadas à geocodificação de endereços.

Neste desafio, serão disponibilizadas duas bases de dados:

1. **CNEFE Bahia**
   Base de referência contendo endereços e seus respectivos setores censitários.
   1. **URL para download 1:** https://www.ibge.gov.br/estatisticas/sociais/populacao/38734-cadastro-nacional-de-enderecos-para-fins-estatisticos.html?=&t=downloads
   2. **URL alternativo para download:** https://fiocruzbr-my.sharepoint.com/:u:/g/personal/robespierre_pita_fiocruz_br/IQBffC24BhqdR6Yxlj-uwH3cAZQO3HzIQLBZocKpMmR7PkE?e=RAynjl
2. **Base de busca**
   Arquivo contendo 100 endereços com diferentes níveis de qualidade, incluindo registros completos, incompletos, padronizados e não padronizados.
   1. **URL para download:** https://fiocruzbr-my.sharepoint.com/:x:/g/personal/robespierre_pita_fiocruz_br/IQBk08ehW4aIRIjamLlzG_w1AbZuys15b1-WD5Q2l4ni3hw?e=MZ6mD5

URL para informações adicionais sobre o CNEFE:
https://www.ibge.gov.br/estatisticas/sociais/populacao/38734-cadastro-nacional-de-enderecos-para-fins-estatisticos.html

Objetivo

Desenvolver uma solução computacional capaz de localizar, na base do CNEFE Bahia, o setor censitário correspondente a cada um dos 100 endereços da base de busca.

O resultado final deve ser uma versão da base de busca contendo uma nova coluna com o setor censitário atribuído a cada endereço.

Exemplo de resultado esperado:

consulta_logradouro	consulta_numero	consulta_bairro	consulta_cep	consulta_complemento	consulta_municipio	setor_censitario_encontrado
RODOVIA BR 101		BR101	48030260	SN	290070	292740805000123
RUA RIO BAIANO	SN	CENTRO	46830000		290130	291230605000456
...	...	...	...	...	...	...

Resultado válido

Será considerada válida qualquer solução computacional que produza, como saída, uma base de dados contendo:

- todos os registros da base de busca original;
- uma coluna adicional com o código do setor censitário encontrado;
- identificação clara dos casos em que não foi possível localizar o setor censitário.

A comissão avaliará a corretude da entrega comparando os setores censitários gerados pela solução com uma base de referência previamente definida como padrão ouro.

Liberdade técnica

Qualquer abordagem computacional será aceita, desde que produza um resultado válido e reprodutível.

A comissão sugere fortemente o uso de:

- Docker;
- GitHub;
- Elasticsearch;
- Spark.

O uso dessas tecnologias não é obrigatório, mas será considerado positivamente quando bem aplicado.

Entregáveis

A pessoa candidata deverá entregar:

Código-fonte da solução

- Preferencialmente em repositório GitHub.
- O repositório deve conter instruções claras de execução.

Arquivo final de resultados

- Base de busca original acrescida da coluna com o setor censitário encontrado.
- Formatos aceitos: .csv, .parquet ou .xlsx.

README

- Explicação breve da abordagem utilizada.
- Passo a passo para executar a solução.
- Dependências necessárias.
- Premissas adotadas.
- Limitações conhecidas da solução.

Opcional

- Dockerfile ou docker-compose.
- Logs de execução.
- Métricas de qualidade da vinculação.
- Estratégias de tratamento de endereços com baixa qualidade.

Critérios de avaliação

A avaliação considerará os seguintes aspectos:

Critério	Peso sugerido
Corretude dos setores censitários atribuídos	40%
Reprodutibilidade da solução	20%
Organização e clareza do código	15%
Qualidade da estratégia de tratamento dos endereços	15%
Documentação da solução	10%

Aspectos que serão observados

A comissão poderá observar se a solução:

- padroniza minimamente os campos de endereço;
- lida com variações de escrita, abreviações e erros simples;
- diferencia casos encontrados, não encontrados e ambíguos;
- produz uma saída clara e auditável;
- permite reexecução por outra pessoa;
- evita processamento manual não documentado;
- organiza bem o fluxo de leitura, processamento e escrita dos dados.

Restrições

Não será aceita uma entrega composta apenas por preenchimento manual da coluna de setor censitário.

A solução deve conter código executável que permita reproduzir o resultado apresentado.

Prazo

18 de Maio de 2026, às 23:55.